

大语言模型攻击性评分中的性别替换偏差 ——研究 1b 实验报告

鲍璇

March 19, 2026

- ① 研究问题与实验设计
- ② 数据结构与维度覆盖
- ③ 统计分析方案
- ④ 核心实证结果
- ⑤ 维度层面的效应解析
- ⑥ 研究局限与后续工作

核心研究问题

当仅将同一攻击性文本中的性别目标词由男性替换为女性时，大语言模型是否会产生系统性差异的攻击性评分？

- **配对设计**：每组句子仅在性别指向措辞上存在差异，其余语义内容保持一致。
- **因变量**：0–6 分攻击性评分（离散等级量表）。
- **被试模型**：Llama Maverick 与 Qwen 2.5 72B。
- **提示条件**：Zero-shot 与 Chain-of-Thought (CoT)。
- **差值定义**：本报告统一采用 **女性版评分 – 男性版评分**。

实验材料

- 数据文件：
1b_groupswap_dimensionsentence.xlsx
- 有效配对样本：371 组
- 每组样本包含：
 - 原始语义模板
 - 男性版句子
 - 女性版句子

评分范式

- 任务类型：攻击性等级评定
- 评分区间：0–6（整数等级）
- 每组配对接受 4 次独立评估：
 - 男性版 Zero-shot
 - 女性版 Zero-shot
 - 男性版 CoT
 - 女性版 CoT

设计的内部效度

- 配对比较有效控制了内容层面的混杂变量。
- 在语义内容、攻击维度及句法结构均保持一致的条件下进行比较。
- 唯一系统性操纵变量为目标性别指称。

结果解读约定

- 若 $F - M > 0$ ：表明模型对女性版赋予了更高的攻击性评分。
- 若 $F - M < 0$ ：表明模型对男性版赋予了更高的攻击性评分。

语料生成与配对构建说明

- **编码框架先行**：语料并非随意拼接，而是先基于相关文献进行整合式归纳，建立攻击性表达的三级编码框架，最终形成 **10 个一级维度、71 个二级维度、183 个三级维度**。
- **语句生成原则**：以各维度的语义特征、攻击对象与表达方式为约束，围绕中文社交媒体中的常见辱骂/贬损表达风格，构造覆盖不同维度的攻击性句子初稿。
- **生成与人工修订结合**：在框架约束下，借助生成模型完成句子初版，再由研究者进行逐条筛查与人工改写；对超过一半的样本进行了显著修订，以提升语感自然度、场景合理性与中文网络表达的真实性。
- **真实性校准**：人工修订过程中参考了微博等中文社交平台中可观察到的辱骂表达方式，但未直接复制现成帖子，而是进行改写、去标识化与语义归并，以避免具体个体信息与平台噪声进入数据集。
- **配对构建方式**：在同一语义模板下，仅替换目标性别指称词，生成男性版与女性版句子，确保两版本在攻击内容、句法结构和强度线索上尽可能保持一致。
- **最终用途**：因此，这 371 组样本可视为一套 **由理论编码框架约束、生成模型辅助起草、研究者深度人工修订并经性别配对构建的攻击性语料集**。

属性	内容
有效配对样本量	371
一级维度	10
二级维度	71
三级维度	183
评估模型	Llama Maverick; Qwen 2.5 72B
提示条件	Zero-shot; CoT
分析面板	4 (模型 $\times$ 提示条件的完全交叉)
分析单元	同一语义模板下的男性版与女性版配对句子

一级维度类别

- 外貌形象、能力才干、智力理性、情绪稳定性、道德品行
- 人际关系、经济资源、社会地位
- 性客体化 (性羞辱)、性别角色与性别表达

- **核心比较指标：** 每组配对的 **女性版评分** — **男性版评分**。
- **总体配对检验**（按面板分别进行）：
 - 均值差及 Bootstrap 95% 置信区间
 - Wilcoxon 符号秩检验
 - 配对效应量 Cohen's d_z
- **方向性分析：**
 - 分类统计女性版评分更高、评分相同、男性版评分更高的样本数
 - 对非零差值样本实施符号检验 (Sign test)
- **维度层面分析：**
 - 在各一级维度内分别进行配对比较
 - 在每个模型 $\times$ 提示条件组合内实施 Benjamini-Hochberg FDR 校正

总体检验结果

模型	提示条件	均值差 $F - M$	95% CI	Wilcoxon q	d_z
Llama Maverick	Zero-shot	0.151	[0.105, 0.197]	6.97×10^{-10}	0.339
Llama Maverick	CoT	0.210	[0.154, 0.264]	5.11×10^{-12}	0.390
Qwen 2.5 72B	Zero-shot	0.224	[0.178, 0.267]	1.13×10^{-18}	0.520
Qwen 2.5 72B	CoT	0.302	[0.253, 0.350]	3.85×10^{-25}	0.648

核心发现

四个分析面板均呈现显著且一致的正向差值：**女性版攻击性评分系统性高于男性版**。此外，Qwen 的偏差效应强于 Llama，且 CoT 提示条件进一步放大了该偏差。

图 1A: 配对攻击性评分 (Llama Maverick · Zero-shot)




图 1B: 配对攻击性评分 (Llama Maverick · CoT)




图 1C: 配对攻击性评分 (Qwen 2.5 72B · Zero-shot)




图 1D: 配对攻击性评分 (Qwen 2.5 72B · CoT)




图 1 解读

- 每条灰线对应一组配对样本。
- 线段两端分别表示同一语义内容下男性版与女性版的评分。
- 黑色标记表示各面板的总体均值及置信区间。
- 四个面板均可观察到从男性版到女性版的评分上移趋势。

关键解释

由于采用被试内配对设计，上述结果并非源于样本间的异质性，而是反映了仅替换性别目标词后模型评分所产生的系统性偏移。

图 2A: 配对分差分布 (Llama Maverick · Zero-shot)




图 2B: 配对分差分布 (Llama Maverick · CoT)

B

Llama Maverick · CoT




图 2C: 配对分差分布 (Qwen 2.5 72B · Zero-shot)




图 2D: 配对分差分布 (Qwen 2.5 72B · CoT)

D

Qwen 2.5 72B · CoT





图 2 解读

- 横轴定义为：**女性版评分** — **男性版评分**。
- 零值线表示无偏差的理论基准。
- 红色实线标示各面板的均值差。
- 所有面板的差值分布均呈现向正值方向的整体偏移。

统计意涵

- 该效应并非由少数极端样本所驱动。
- 配对差值的整体分布呈现系统性右移，表明偏差具有普遍性。
- Qwen 的偏移幅度显著大于 Llama。

图 3：分差方向比例



堆叠柱表示女版更高、两者相同、男版更高的比例构成；柱顶文字给出原始计数与符号检验校正 q 值。

方向性检验结果

模型	提示条件	$F > M$	$F = M$	$F < M$	Sign-test q
Llama Maverick	Zero-shot	62	301	8	1.83×10^{-11}
Llama Maverick	CoT	71	294	6	4.56×10^{-15}
Qwen 2.5 72B	Zero-shot	83	287	1	1.76×10^{-23}
Qwen 2.5 72B	CoT	111	260	0	3.08×10^{-33}

结果的重要性

尽管评分一致的配对占较大比例，但在产生差异的样本中，方向性高度集中于女性版评分更高。尤其在 Qwen + CoT 条件下，该单向偏差近乎绝对。

图 4A：一级维度森林图 (Llama Maverick · Zero-shot)




图 4B：一级维度森林图 (Llama Maverick · CoT)




图 4C：一级维度森林图（Qwen 2.5 72B · Zero-shot）





图 4D：一级维度森林图（Qwen 2.5 72B · CoT）



维度层面效应解析

模型	提示条件	维度	统计证据
Qwen 2.5 72B	CoT	性客体化（性羞辱）	均值差 $F - M = 0.545$, FDR 校正 $q = 5.70 \times 10^{-4}$
Llama Maverick	CoT	性客体化（性羞辱）	均值差 $F - M = 0.364$, FDR 校正 $q = 8.999 \times 10^{-3}$
Llama Maverick	CoT	社会地位	均值差 $F - M = 0.361$, FDR 校正 $q = 3.01 \times 10^{-2}$
Qwen 2.5 72B	Zero-shot	性客体化（性羞辱）	均值差 $F - M = 0.394$, FDR 校正 $q = 1.97 \times 10^{-3}$
Qwen 2.5 72B	Zero-shot	情绪稳定性	均值差 $F - M = 0.368$, FDR 校正 $q = 1.77 \times 10^{-3}$

- 偏差效应在各语义维度间并非均匀分布，呈现出维度特异性。
- 性客体化（性羞辱）维度在两个模型中均表现为偏差最为显著的维度。
- 相较于 Llama，Qwen 在更多维度上呈现出更强且更为稳健的正向偏差。

- ① 研究 1b 提供了 **性别目标偏差**存在的充分实证证据。
- ② 偏差方向高度一致：**女性版句子被系统性赋予更高的攻击性评分。**
- ③ 偏差效应量存在显著的 **模型间差异**：Qwen > Llama。
- ④ 偏差效应量同时受 **提示策略**调节：CoT > Zero-shot。
- ⑤ 该偏差在特定语义维度（尤其是性客体化维度）中表现尤为集中。

- 被试内配对设计有效控制了语义内容差异所引入的混杂变量。
- 描述性统计与推断性统计提供了高度一致的收敛性证据：
 - 均值差与 Bootstrap 置信区间
 - Wilcoxon 符号秩检验
 - 方向性符号检验
 - 效应量估计及 FDR 校正后的维度层面结果
- 综上，本研究结果兼具可解释性与统计稳健性。

- 因变量为 0–6 离散等级评分，效应量的实际意义需结合量表粒度审慎解读。
- 评分一致的配对占比较高，表明偏差虽具系统性，但并非在每组样本中均会被触发。
- 本报告聚焦一级维度层面的分析；若需深入探讨偏差的认知机制，尚需补充二级与三级维度的精细化分析。
- 当前结论基于两个特定模型，向更广泛的大语言模型生态推广尚需进一步实证验证。

- 补充二级维度分析及极端样本的个案考察。
- 构建混合效应模型（Mixed-effects model）或有序回归模型（Ordinal regression），将性别版本、模型类型、提示策略等因素同时纳入分析框架。
- 将本研究的分析范式迁移至其他毒性检测与仇恨言论评分任务，以检验结论的可重复性。
- 进一步检验不同措辞模板及维度子集下结果的稳健性。

核心结论

在研究 1b 中，仅替换攻击性文本中的性别目标词，即可导致模型对女性版本产生系统性更高的攻击性评分。

- 全部四个模型 × 提示条件面板均达到统计显著水平。
- Qwen 模型的偏差效应量最大。
- CoT 提示策略对偏差具有显著的放大效应。
- 偏差在特定语义维度上呈现明显的聚集特征。