

大语言模型攻击性评分中的性别替换偏差 ——研究 1b 实验报告

鲍璇

March 18, 2026

报告结构

- ① 研究问题与实验设计
- ② 数据结构与维度覆盖
- ③ 统计分析方案
- ④ 核心实证结果
- ⑤ 维度层面的效应解析
- ⑥ 研究局限与后续工作

核心研究问题

当仅将同一攻击性文本中的性别目标词由男性替换为女性时，大语言模型是否会产生系统性差异的攻击性评分？

- **配对设计**：每组句子仅在性别指向措辞上存在差异，其余语义内容保持一致。
- **因变量**：0–6 分攻击性评分（离散等级量表）。
- **被试模型**：Llama Maverick 与 Qwen 2.5 72B。
- **提示条件**：Zero-shot 与 Chain-of-Thought (CoT)。
- **差值定义**：本报告统一采用 **女性版评分 – 男性版评分**。

实验材料

- 数据文件：
1b_groupswap_demensionsentence.xlsx
- 有效配对样本：371 组
- 每组样本包含：
 - 原始语义模板
 - 男性版句子
 - 女性版句子

评分范式

- 任务类型：攻击性等级评定
- 评分区间：0–6（整数等级）
- 每组配对接受 4 次独立评估：
 - 男性版 Zero-shot
 - 女性版 Zero-shot
 - 男性版 CoT

设计的内部效度

- 配对比较有效控制了内容层面的混杂变量。
- 在语义内容、攻击维度及句法结构均保持一致的条件下进行比较。
- 唯一系统性操纵变量为目标性别指称。

结果解读约定

- 若 $F - M > 0$ ：表明模型对女性版赋予了更高的攻击性评分。
- 若 $F - M < 0$ ：表明模型对男性版赋予了更高的攻击性评分。

属性	内容
有效配对样本量	371
一级维度	10
二级维度	71
三级维度	183
评估模型	Llama Maverick; Qwen 2.5 72B
提示条件	Zero-shot; CoT
分析面板	4 (模型 $\times$ 提示条件的完全交叉)
分析单元	同一语义模板下的男性版与女性版配对句子

一级维度类别

- 外貌形象、能力才干、智力理性、情绪稳定性、道德品行
- 人际关系、经济资源、社会地位
- 性客体化（性羞辱）、性别角色与性别表达

- **核心比较指标：** 每组配对的 **女性版评分** — **男性版评分**。
- **总体配对检验**（按面板分别进行）：
 - 均值差及 Bootstrap 95% 置信区间
 - Wilcoxon 符号秩检验
 - 配对效应量 Cohen's d_z
- **方向性分析：**
 - 分类统计女性版评分更高、评分相同、男性版评分更高的样本数
 - 对非零差值样本实施符号检验 (Sign test)
- **维度层面分析：**
 - 在各一级维度内分别进行配对比较
 - 在每个模型 $\times$ 提示条件组合内实施 Benjamini-Hochberg FDR 校正

总体检验结果

模型	提示条件	均值差 $F - M$	95% CI	Wilcoxon q	d_z
Llama Maverick	Zero-shot	0.151	[0.105, 0.197]	6.97×10^{-10}	0.339
Llama Maverick	CoT	0.210	[0.154, 0.264]	5.11×10^{-12}	0.390
Qwen 2.5 72B	Zero-shot	0.224	[0.178, 0.267]	1.13×10^{-18}	0.520
Qwen 2.5 72B	CoT	0.302	[0.253, 0.350]	3.85×10^{-25}	0.648

核心发现

四个分析面板均呈现显著且一致的正向差值：**女性版攻击性评分系统性高于男性版**。此外，Qwen 的偏差效应强于 Llama，且 CoT 提示条件进一步放大了该偏差。

图 1A: 配对攻击性评分 (Llama Maverick · Zero-shot)




图 1B: 配对攻击性评分 (Llama Maverick · CoT)




图 1C: 配对攻击性评分 (Qwen 2.5 72B • Zero-shot)




图 1D: 配对攻击性评分 (Qwen 2.5 72B · CoT)




图 1 解读

- 每条灰线对应一组配对样本。
- 线段两端分别表示同一语义内容下男性版与女性版的评分。
- 黑色标记表示各面板的总体均值及置信区间。
- 四个面板均可观察到从男性版到女性版的评分上移趋势。

关键解释

由于采用被试内配对设计，上述结果并非源于样本间的异质性，而是反映了仅替换性别目标词后模型评分所产生的系统性偏移。

图 2A: 配对分差分布 (Llama Maverick · Zero-shot)




图 2B: 配对分差分布 (Llama Maverick · CoT)

B

Llama Maverick · CoT




图 2C：配对分差分布 (Qwen 2.5 72B · Zero-shot)




图 2D: 配对分差分布 (Qwen 2.5 72B · CoT)

D

Qwen 2.5 72B · CoT





图 2 解读

- 横轴定义为：**女性版评分** — **男性版评分**。
- 零值线表示无偏差的理论基准。
- 红色实线标示各面板的均值差。
- 所有面板的差值分布均呈现向正值方向的整体偏移。

统计意涵

- 该效应并非由少数极端样本所驱动。
- 配对差值的整体分布呈现系统性右移，表明偏差具有普遍性。
- Qwen 的偏移幅度显著大于 Llama。

图 3：分差方向比例



堆叠柱表示女版更高、两者相同、男版更高的比例构成；柱顶文字给出原始计数与符号检验校正 q 值。

方向性检验结果

模型	提示条件	$F > M$	$F = M$	$F < M$	Sign-test q
Llama Maverick	Zero-shot	62	301	8	1.83×10^{-11}
Llama Maverick	CoT	71	294	6	4.56×10^{-15}
Qwen 2.5 72B	Zero-shot	83	287	1	1.76×10^{-23}
Qwen 2.5 72B	CoT	111	260	0	3.08×10^{-33}

结果的重要性

尽管评分一致的配对占较大比例，但在产生差异的样本中，方向性高度集中于女性版评分更高。尤其在 Qwen + CoT 条件下，该单向偏差近乎绝对。

图 4A：一级维度森林图 (Llama Maverick · Zero-shot)




图 4B：一级维度森林图 (Llama Maverick · CoT)




图 4C：一级维度森林图 (Qwen 2.5 72B · Zero-shot)





图 4D：一级维度森林图（Qwen 2.5 72B · CoT）



维度层面效应解析

模型	提示条件	维度	统计证据
Qwen 2.5 72B	CoT	性客体化（性羞辱）	均值差 $F - M = 0.545$, FDR 校正 $q = 5.70 \times 10^{-4}$
Llama Maverick	CoT	性客体化（性羞辱）	均值差 $F - M = 0.364$, FDR 校正 $q = 8.999 \times 10^{-3}$
Llama Maverick	CoT	社会地位	均值差 $F - M = 0.361$, FDR 校正 $q = 3.01 \times 10^{-2}$
Qwen 2.5 72B	Zero-shot	性客体化（性羞辱）	均值差 $F - M = 0.394$, FDR 校正 $q = 1.97 \times 10^{-3}$
Qwen 2.5 72B	Zero-shot	情绪稳定性	均值差 $F - M = 0.368$, FDR 校正 $q = 1.77 \times 10^{-3}$

- 偏差效应在各语义维度间并非均匀分布，呈现出维度特异性。
- 性客体化（性羞辱）维度在两个模型中均表现为偏差最为显著的维度。
- 相较于 Llama，Qwen 在更多维度上呈现出更强且更为稳健的正向偏差。

- ① 研究 1b 提供了 **性别目标偏差**存在的充分实证证据。
- ② 偏差方向高度一致：**女性版句子被系统性赋予更高的攻击性评分。**
- ③ 偏差效应量存在显著的 **模型间差异**：Qwen > Llama。
- ④ 偏差效应量同时受 **提示策略**调节：CoT > Zero-shot。
- ⑤ 该偏差在特定语义维度（尤其是性客体化维度）中表现尤为集中。

- 被试内配对设计有效控制了语义内容差异所引入的混杂变量。
- 描述性统计与推断性统计提供了高度一致的收敛性证据：
 - 均值差与 Bootstrap 置信区间
 - Wilcoxon 符号秩检验
 - 方向性符号检验
 - 效应量估计及 FDR 校正后的维度层面结果
- 综上，本研究结果兼具可解释性与统计稳健性。

- 因变量为 0–6 离散等级评分，效应量的实际意义需结合量表粒度审慎解读。
- 评分一致的配对占比较高，表明偏差虽具系统性，但并非在每组样本中均会被触发。
- 本报告聚焦一级维度层面的分析；若需深入探讨偏差的认知机制，尚需补充二级与三级维度的精细化分析。
- 当前结论基于两个特定模型，向更广泛的大语言模型生态推广尚需进一步实证验证。

- 补充二级维度分析及极端样本的个案考察。
- 构建混合效应模型（Mixed-effects model）或有序回归模型（Ordinal regression），将性别版本、模型类型、提示策略等因素同时纳入分析框架。
- 将本研究分析范式迁移至其他毒性检测与仇恨言论评分任务，以检验结论的可重复性。
- 进一步检验不同措辞模板及维度子集下结果的稳健性。

核心结论

在研究 1b 中，仅替换攻击性文本中的性别目标词，即可导致模型对女性版本产生系统性更高的攻击性评分。

- 全部四个模型 × 提示条件面板均达到统计显著水平。
- Qwen 模型的偏差效应量最大。
- CoT 提示策略对偏差具有显著的放大效应。
- 偏差在特定语义维度上呈现明显的聚集特征。