

攻击性评分中的性别替换偏差 研究 1b 汇报

Builder

March 18, 2026

- ① 研究问题与实验设计
- ② 数据结构与维度覆盖
- ③ 统计分析方案
- ④ 四张主图的核心结果
- ⑤ 维度层面的解释
- ⑥ 局限性与下一步工作

核心问题

如果仅仅把同一句攻击性文本中的性别目标词从男性版本替换为女性版本，大语言模型会不会给出系统性不同的攻击性评分？

- 配对设计：每一对句子只在性别指向措辞上不同。
- 结果变量：0-6 分攻击性评分。
- 两个模型：Llama Maverick 与 Qwen 2.5 72B。
- 两种提示设置：Zero-shot 与 Chain-of-Thought (CoT)。
- 本汇报统一使用的差值定义：**女人版评分** – **男人版评分**。

输入数据

- 文件：
1b_groupswap_demensionsentence.xlsx
- 共 371 条可用配对样本
- 每条样本包含：
 - 原始语义模板
 - 男人版句子
 - 女人版句子

打分方式

- 任务模式：攻击性评分
- 分值区间：0–6
- 每个配对共进行 4 次评估：
 - 男人版 Zero-shot
 - 女人版 Zero-shot
 - 男人版 CoT

为什么这个设计有说服力

- 配对比较能最大限度消除内容层面的混杂因素。
- 同一条语义内容、同一维度、同一结构下进行比较。
- 被操纵的核心因素主要就是目标性别措辞。

结果解释规则

- 若 $F - M > 0$ ：说明女人版被打得更高，更“攻击”。
- 若 $F - M < 0$ ：说明男人版被打得更高。

属性	内容
可用配对样本数	371
一级维度数量	10
二级维度数量	71
三级维度数量	183
模型	Llama Maverick; Qwen 2.5 72B
提示设置	Zero-shot; CoT
总体分析面板	4 个模型 × 设置组合
推断单位	同一条样本中的男人版句子 vs 女人版句子

一级维度示例

- 外貌形象攻击、能力才干攻击、智力理性攻击、情绪稳定攻击、道德品行攻击
- 人际关系攻击、经济资源攻击、社会地位攻击
- 性化攻击（性羞辱）、性别角色/性别表达攻击

- **主比较量：**每个配对样本的 **女人版评分** — **男人版评分**。
- **每个面板的总体配对统计：**
 - 平均分差及 bootstrap 95% CI
 - Wilcoxon signed-rank test
 - Cohen's d_z
- **方向性分析：**
 - 统计女人版更高 / 相同 / 男人版更高的数量
 - 对非零差值样本做 sign test
- **维度层面分析：**
 - 在每个一级维度内做配对比较
 - 在每个模型 $\times$ 设置切片内做 BH-FDR 校正

总体结果汇总

模型	设置	平均分差 $F - M$	95% CI	Wilcoxon q	d_z
Llama Maverick	Zero-shot	0.151	[0.105, 0.197]	6.97×10^{-10}	0.339
Llama Maverick	CoT	0.210	[0.154, 0.264]	5.11×10^{-12}	0.390
Qwen 2.5 72B	Zero-shot	0.224	[0.178, 0.267]	1.13×10^{-18}	0.520
Qwen 2.5 72B	CoT	0.302	[0.253, 0.350]	3.85×10^{-25}	0.648

核心结论

四个面板全部显示出稳定的正向分差：**女人版的攻击性评分系统性高于男人版**。同时，Qwen 的偏差强于 Llama，而 CoT 会进一步放大这种偏差。

图 1：配对攻击性评分

图1：性别替换句子版本的配对攻击性评分




图 1 解读

- 每条灰线代表一条配对样本。
- 线的两端分别是同一句语义内容下的男人版评分与女人版评分。
- 黑色标记给出每个面板的总体均值和区间估计。
- 四个面板都能看到从男人版到女人版的整体上移趋势。

解释重点

由于这里是同一条样本内部的比较，因此结果并不是由样本之间的异质性驱动，而是更接近于“仅替换性别目标词后，模型给出的评分发生了系统偏移”。

图 2：配对分差分布

图2：配对分差分布（女版 - 男版）





图 2 解读

- 横轴定义为：**女人版评分** — **男人版评分**。
- 0 线表示完全没有偏差。
- 红色实线表示每个面板的平均分差。
- 所有面板的分布都整体向正值一侧偏移。

含义

- 这不是少数极端样本拉出来的假象。
- 更像是整个配对分差分布发生了系统右移。
- Qwen 的右移幅度明显大于 Llama。

图 3：分差方向比例



方向性结果汇总


模型	设置	女人版更高	相同	男人版更高	Sign-test q
Llama Maverick	Zero-shot	62	301	8	1.83×10^{-11}
Llama Maverick	CoT	71	294	6	4.56×10^{-15}
Qwen 2.5 72B	Zero-shot	83	287	1	1.76×10^{-23}
Qwen 2.5 72B	CoT	111	260	0	3.08×10^{-33}

为什么这个结果重要

即使把大量“相同分数”的样本算进去，在真正出现差异的样本里，方向依然极度偏向女人版更高。尤其是 Qwen + CoT，几乎呈现压倒性的单边方向。

图 4：一级维度 forest plot

图4：一级维度效应及其 95% 置信区间（按绝对效应排序）



维度层面解释

模型	设置	维度	证据
Qwen 2.5 72B	CoT	性化攻击（性羞辱）	平均分差 $F - M = 0.545$, FDR 校正后 Wilcoxon $q = 5.70 \times 10^{-4}$
Llama Maverick	CoT	性化攻击（性羞辱）	平均分差 $F - M = 0.364$, FDR 校正后 Wilcoxon $q = 8.999 \times 10^{-3}$
Llama Maverick	CoT	社会地位攻击	平均分差 $F - M = 0.361$, FDR 校正后 Wilcoxon $q = 3.01 \times 10^{-2}$
Qwen 2.5 72B	Zero-shot	性化攻击（性羞辱）	平均分差 $F - M = 0.394$, FDR 校正后 Wilcoxon $q = 1.97 \times 10^{-3}$
Qwen 2.5 72B	Zero-shot	情绪稳定攻击	平均分差 $F - M = 0.368$, FDR 校正后 Wilcoxon $q = 1.77 \times 10^{-3}$

- 偏差并不是在所有语义维度上完全均匀分布的。
- 性化攻击（性羞辱）是两个模型里都尤其敏感的偏差维度。
- 相比 Llama, Qwen 在更多维度上表现出更强、更稳定的正向偏差。

- ① 研究 1b 清晰地显示出 **性别目标偏差**的存在。
- ② 这种偏差的方向高度一致：**女人版句子更容易被打成更高攻击性**。
- ③ 偏差强度具有 **模型差异**：Qwen > Llama。
- ④ 偏差还具有 **提示方式差异**：CoT > Zero-shot。
- ⑤ 这种偏差在若干具有明确语义含义的维度中更为集中和突出。

- 同一样本内部的配对比较，大幅削弱了内容差异带来的混杂。
- 描述统计和推断统计给出了相互一致的证据：
 - 平均分差与置信区间
 - signed-rank test
 - directionality sign test
 - 效应量与 FDR 校正后的维度结果
- 因此，这组结果既有可解释性，也有统计稳健性。

- 评分变量是离散 0–6 分，因此效应量解释需要结合量表粒度来看。
- 相同分数的样本占比较高，说明偏差虽稳定存在，但并不是每条样本都会触发显著差异。
- 本汇报重点展示一级维度；如果要进一步做机制层面的解释，仍应补充二级和三级维度分析。
- 当前结论建立在这两个模型之上，对更广泛模型生态的泛化仍需继续验证。

下一步建议

- 增补二级维度与极端样本的补充页。
- 建立 mixed-effects 或 ordinal regression 模型，同时纳入性别版本、模型、提示方式等因素。
- 将该分析框架迁移到其他 toxicity / hate scoring 任务中，检验可重复性。
- 继续测试不同措辞模板和不同维度子集下的稳健性。

一句话结论

在研究 1b 中，仅仅替换攻击性句子中的性别目标词，就足以让模型对女人版给出系统性更高的攻击性评分。

- 四个模型 × 设置面板全部显著。
- Qwen 的偏差最强。
- CoT 会放大这种偏差。
- 偏差在若干语义维度上具有更明确的集中性。